MÓDULO 2 — MANIPULAÇÃO DE DADOS COM PANDAS

Curso de Introdução à Ciência de Dados

UNIFOR

DISCIPLINA: CIÊNCIA DE DADOS

OBJETIVOS DO MÓDULO

- Entender o que é o **Pandas** e sua importância na Ciência de Dados.
- Carregar e explorar **dados reais** de forma eficiente.
- Realizar **filtros e análises estatísticas** para gerar insights.
- Trabalhar com **DataFrames**, a estrutura fundamental para tabelas.
- Limpar e tratar dados **"bagunçados"** (valores nulos e duplicados).

O QUE É O PANDAS?

BIBLIOTECA PYTHON

Líder para manipulação e análise de dados estruturados em todo o mundo.

TABELAS (DATAFRAMES)

Permite operações rápidas em grandes volumes de dados de forma intuitiva.

TRANSFORMAÇÃO

Facilita a conversão de dados brutos em informações úteis para decisão.

A FERRAMENTA NÚMERO 1 PARA CIENTISTAS DE DADOS

O DESAFIO DOS DADOS REAIS

- **Valores Faltantes:** Buracos que distorcem médias.
- **Dados Duplicados:** Registros repetidos e redundantes.
- **Formatos Errados:** Números lidos como texto.

DADOS SÃO "BAGUNÇADOS"

Na vida real, os dados raramente vêm prontos. O tratamento é a etapa mais crítica do projeto.

IMPORTAÇÃO E CARGA

1. IMPORTAR BIBLIOTECA

O primeiro passo é importar o Pandas usando o alias padrão 'pd'.

```
import pandas as pd
```

2. CARREGAR CSV

Lemos arquivos externos (como .csv) diretamente para um DataFrame.

```
df = pd.read_csv("brazilian_cities.csv")
```

3. VISUALIZAÇÃO INICIAL

Use o método head() para verificar se os dados foram carregados corretamente.

```
df.head() # Exibe as primeiras 5 linhas
```

EXPLORANDO A ESTRUTURA

TAMANHO DA BASE

Retorna uma tupla com o número de linhas e colunas da tabela.

```
df.shape
```

RESUMO TÉCNICO

Exibe tipos de dados e identifica valores nulos em cada coluna.

```
df.info()
```

ESTATÍSTICAS DESCRITIVAS

Gera automaticamente média, desvio padrão, mínimo e máximo.

```
df.describe()
```

"Conhecer a estrutura é o primeiro passo para uma análise de dados confiável."

LIMPEZA E TRATAMENTO

VALORES NULOS

Identificamos "buracos" nos dados que podem distorcer análises estatísticas e modelos.

DUPLICATAS

Registros repetidos geram contagens erradas e devem ser removidos para garantir a integridade.

IDENTIFICAR E PREENCHER

```
df.isnull().sum()
df["IDHM"].fillna(df["IDHM"].median())
```

REMOVER REPETIÇÕES

```
df.duplicated().sum()
df = df.drop_duplicates()
```

FILTRAGEM DE DADOS

Filtro Simples: Selecionar cidades com população > 100k.

```
df[df["ESTIMATED_POP"] > 100000]
```

Filtro Composto: Capitais com IDHM acima de 0.75.

```
df[(df["CAPITAL"] == 1) & (df["IDHM"] > 0.75)]
```

Ordenação: Criar rankings baseados em colunas.

```
df.sort_values("GDP", ascending=False)
```

TRANSFORMAÇÃO DE DADOS

NOVAS COLUNAS

Crie indicadores de valor (KPIs) a partir de dados existentes na tabela.

```
df["DENSIDADE"] = df["POP"] / df["AREA"]
```

CONVERSÃO DE TIPOS

Garanta que números lidos como texto sejam convertidos para cálculos.

```
df["GDP"] = pd.to_numeric(df["GDP"],
errors="coerce")
```

AGRUPAMENTO DE DADOS

O PODER DO GROUP BY

A função mais poderosa para resumir dados por categorias, permitindo comparar o desempenho de diferentes grupos de forma justa.

ESTATÍSTICAS DE GRUPO

Podemos aplicar diversas funções após o agrupamento, como média, mediana, soma e contagem.

```
# Média de PIB por Estado
df.groupby("STATE")["GDP"].mean()
```

```
# Resumo do IDHM
df["IDHM"].mean()
df["IDHM"].median()
```

Insight: O agrupamento transforma milhares de linhas em uma visão estratégica por categoria.

INSIGHTS E CONCLUSÕES

CORRELAÇÃO DE RIQUEZA

Cidades com maior densidade populacional tendem a concentrar um PIB total significativamente mais elevado.

QUALIDADE DE VIDA

As capitais brasileiras mantêm, em média, os melhores índices de IDHM devido à infraestrutura e serviços.

VALOR DOS DADOS

O tratamento rigoroso transforma ruído em sinal, permitindo decisões baseadas em fatos, não em suposições.

"Sem dados bem tratados, não existe boa análise."

RESUMO E PRÓXIMOS PASSOS

- Pandas é Essencial: A base para quase todo projeto de Ciência de Dados em Python.
- Processo Iterativo: Limpar, explorar e filtrar é um ciclo constante de melhoria.
- Prática Contínua: Explore novos datasets para ganhar fluidez nos comandos.
- Dúvidas? Estamos à disposição para ajudar na sua jornada de aprendizado!

PRÓXIMO MÓDULO

VISUALIZAÇÃO DE DADOS (MÓDULO 3)