MÓDULO 4 — ANÁLISE EXPLORATÓRIA DE DADOS (EDA)

Investigando dados reais para gerar insights

Curso de Python para Ciência de Dados

O QUE É EDA?

Definição

Exploratory Data Analysis é o processo de investigar um dataset para entender sua estrutura fundamental, identificar padrões ocultos e detectar anomalias.

> *"É o que um detetive faz com dados antes de apontar um culpado."*

O Timing Perfeito

A EDA vem **ANTES** de tirar conclusões precipitadas ou construir modelos complexos de Machine Learning.

Integração Total

Combina o poder de manipulação do **Python + Pandas** com a clareza da **Visualização de Dados**.

POR QUE EDA É TÃO IMPORTANTE?

Sem EDA você pode:

- Tirar conclusões erradas baseadas em ruído.
- Construir modelos com dados "sujos" ou enviesados.
- Ignorar padrões críticos para o negócio.

Com EDA você:

- Conhece a verdade por trás dos seus dados.
- Identifica problemas antes que virem erros graves.
- Descobre os insights que realmente guiam a análise.

"A EDA gera os insights fundamentais que guiam toda a estratégia posterior."

O PROCESSO DE EDA (AS 7 ETAPAS)

ETAPA 1

Definir o problema e as perguntas

ETAPA 2

Carregar os dados (Ingestão)

ETAPA 3

Limpeza e tratamento

ETAPA 4

Estatística descritiva

ETAPA 5

Visualizações exploratórias

ETAPA 6

Storytelling com os dados

ETAPA 7

Conclusões e insights

ETAPA 1: FORMULAR O PROBLEMA

Antes de abrir qualquer tabela ou escrever uma linha de código, defina o seu norte.

Qual é a pergunta central que sua análise deve responder?

Quais são as perguntas norteadoras que detalham o problema?

O que você espera descobrir ou validar com esses dados?

Exemplo do Módulo:

"Quais fatores socioeconômicos (educação, renda, infraestrutura) mais influenciam o IDHM dos municípios brasileiros e como isso evoluiu no tempo?"

ETAPA 2: CONHECER O DATASET

df.shape

Retorna o número de linhas e colunas.

df.head()

Exibe as primeiras 5 linhas do dataset.

df.info()

Mostra tipos de dados e valores nulos.

df.describe()

Gera estatísticas descritivas básicas.

df.columns.tolist()

Lista todos os nomes das variáveis.

```
# Primeiro contato com os dados
df = pd.read_csv('atlas_adh.csv')

# Verificando dimensões
print(df.shape)

# Espiando os dados
df.head()

# Resumo técnico
df.info()

# Estatísticas rápidas
df.describe()
```

>_ Dica: Use estes comandos logo após carregar qualquer arquivo.

ETAPA 3: LIMPEZA DE DADOS

Problemas Comuns

- Valores ausentes (NaN)
- Registros duplicados
- Tipos errados (número como texto)
- Valores inconsistentes

Comandos Essenciais

```
# Identificar e tratar
df.isnull().sum()
df.dropna()
df.fillna(valor)

# Remover duplicatas
df.drop_duplicates()
```

Regra de Ouro: Nunca altere o DataFrame original diretamente — use sempre .copy()

ETAPA 4: ESTATÍSTICA DESCRITIVA

◎ Centralidade

- **Média:** Valor médio (sensível a outliers)
- **Mediana:** Valor central (robusta)
- **Moda:** Valor mais frequente

↔ Dispersão

- **Desvio Padrão:** Afastamento da média
- **Variância:** Dispersão quadrática
- **Amplitude:** Máximo - Mínimo

Distribuição

- **Percentis:** Divisão em 100 partes
- **Quartis:** Divisão em 4 partes
- **Outliers:** Valores atípicos

```
df.describe()
```

Diferença Crucial: *A média é puxada por valores extremos (outliers), enquanto a mediana permanece estável, representando melhor o "centro" em dados desiguais.*

ETAPA 5: VISUALIZAÇÕES EXPLORATÓRIAS

O QUE VOCÊ QUER SABER?	MELHOR TIPO DE GRÁFICO
Como os dados mudam no tempo?	Gráfico de Linha
Como os grupos se comparam?	Barras ou Boxplot
Qual a frequência dos valores?	Histograma
Existe relação entre duas variáveis?	Scatterplot (Dispersão)
Quais variáveis "andam juntas"?	Heatmap (Mapa de Calor)

*"Um gráfico por **pergunta**. Uma interpretação por **gráfico**."*

DATASET DO MÓDULO: ATLAS ADH

O **Atlas do Desenvolvimento Humano** é uma base de dados fundamental para entender a realidade socioeconômica do Brasil.

Todos os municípios brasileiros

Anos: 1991, 2000 e 2010

+230 variáveis disponíveis

VARIÁVEL	DESCRIÇÃO
`idhm`	Índice de Desenvolvimento Humano Municipal (0 a 1)
`renda_pc`	Renda per capita média do município
`indice_gini`	Medida de desigualdade (0 = igualdade, 1 = máxima)
`taxa_analfabetismo`	% de adultos (15+ anos) que não sabem ler/escrever
`taxa_agua_encanada`	% de domicílios com acesso a água encanada

RESULTADOS: EVOLUÇÃO DO IDHM

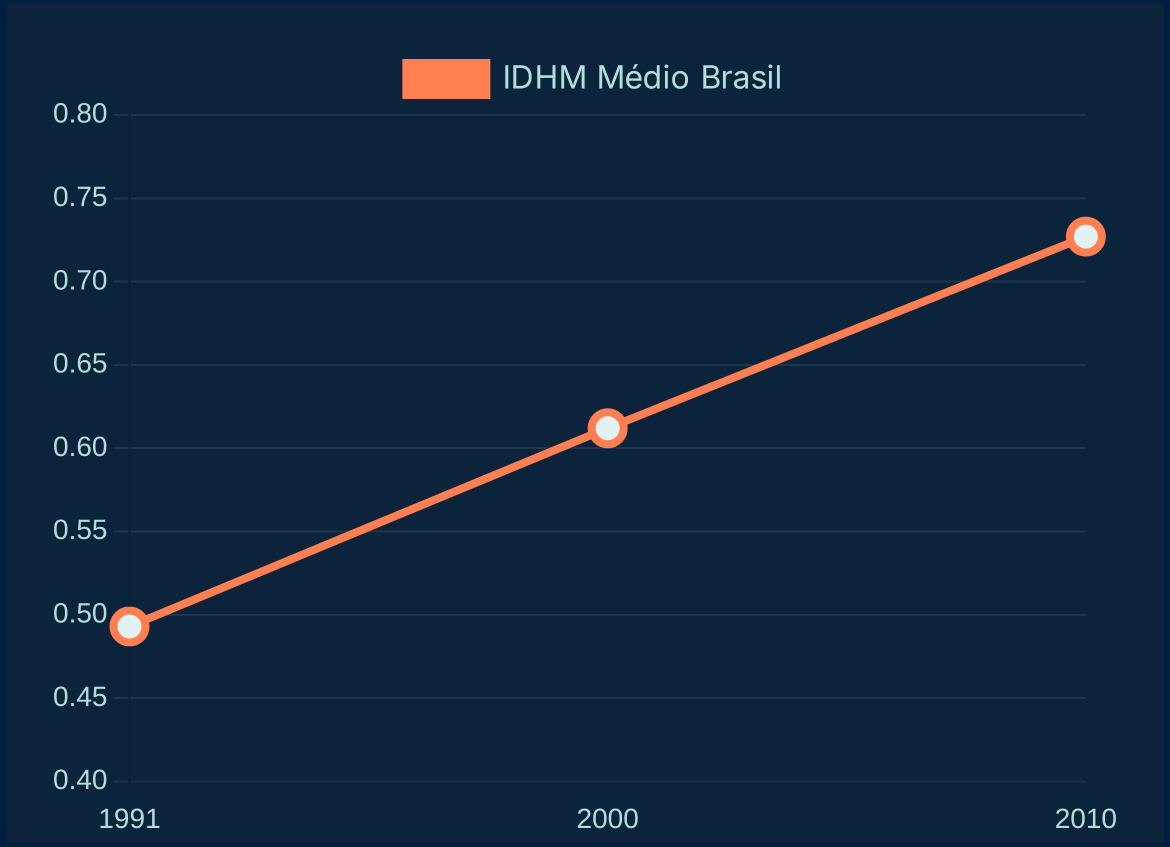

O IDHM médio brasileiro saltou de **0.493** em 1991 para **0.727** em 2010 — um crescimento de aproximadamente **35%**.

Embora todas as regiões tenham apresentado melhoras, o hiato entre o Sul/Sudeste e o Norte/Nordeste permanece um desafio.

"O Brasil avançou significativamente, mas a desigualdade regional ainda é a marca do nosso desenvolvimento."

O QUE MAIS INFLUENCIA O IDHM?

Analfabetismo × IDHM

~ -0.85

Correlação Negativa Forte

Renda per capita × IDHM

Positiva Forte

Impacto Direto

Água Encanada × IDHM

Positiva Forte

Infraestrutura Básica

Índice de Gini × IDHM

Negativa

Desigualdade Social

CONCLUSÃO VISUAL: EDUCAÇÃO É A CHAVE

A redução do analfabetismo é o fator com maior poder preditivo para o aumento do IDHM.

STORYTELLING COM DADOS

> Storytelling é a arte de organizar seus insights técnicos em uma narrativa coerente que gera impacto e ação.

Contexto	Conflito	Dados	Insight	Recomendação

Exemplo Prático:

"O Brasil avançou significativamente no IDHM nas últimas décadas, mas esse progresso não foi uniforme. Os dados revelam que a educação foi o motor principal, mas a desigualdade regional ainda é o nosso maior desafio para o futuro."

ETAPA 7: CONCLUSÕES E INSIGHTS

Educação é o pilar central: É o fator com a correlação mais forte e consistente com o IDHM em todas as décadas analisadas.

Infraestrutura como base: Acesso a água e energia funciona como um patamar mínimo necessário para o desenvolvimento inicial.

O peso da desigualdade: Municípios com alta desigualdade (Gini) tendem a não converter ganhos de renda em bem-estar social.

Convergência regional: O Nordeste apresentou o maior crescimento proporcional, reduzindo a distância histórica para o Sul.

LEMBRETE FUNDAMENTAL: CORRELAÇÃO NÃO IMPLICA CAUSALIDADE

RESUMO DO MÓDULO

O QUE APRENDEMOS:

- Conceitos e importância da EDA
- As 7 etapas do processo analítico
- Formulação de perguntas norteadoras
- Limpeza e visualização integradas
- Storytelling e geração de insights

Próximo Passo

Projeto Final:
É hora de aplicar tudo o que você aprendeu em uma análise completa utilizando um dataset real do zero!

Parabéns por concluir o Módulo 4! Nos vemos no projeto final.